

# 엔트로피 및 KL 발산 정규화를 적용한 대조 학습 기반 추천 시스템

## 초록

본 제안에서는 대조 학습(Contrastive Learning)과 정보 이론적 정규화를 결합한 새로운 추천 시스템 문제를 정의하고 자 한다. 기존의 대조 학습 기반 추천 연구에서는 임베딩 정렬(alignment)과 균일화(uniformity)를 통해 표현의 분산도를 높여 왔으나 <sup>1</sup>, 사용자별 선호 분포를 고려한 분포 조절을 수행하지 못한다. 우리는 사용자 선호 분포와 추천 결과 분포 간 KL 발산을 최소화하고, 추천 결과의 엔트로피를 최대화하도록 하는 새로운 목적 함수를 제안한다. 이와 같은 목적 함수를 이론적으로 분석하고 표준 추천 데이터셋(예: MovieLens, Amazon 등)을 사용해 실험적으로 평가함으로써, 추천의 정확도와 다양성 간 균형을 제시할 예정이다. 실험 결과 사용자 관심 분포와 잘 일치하는 다양하고 신뢰도 높은 추천을 달성할 것으로 기대한다.

## 배경 및 동기

추천 시스템은 사용자 경험을 크게 향상시키는 기술이지만, 전통적 협업 필터링 모델은 데이터 희소성, 인기도 편향(popularity bias) 등의 한계를 지닌다. 이러한 한계를 보완하기 위해 최근 대조 학습 기반 추천 기법이 주목받고 있다 <sup>1</sup>. 예를 들어 SimGCL과 SGL 등은 그래프 증강이나 노이즈 주입을 통해 임베딩 공간에서 표현을 균일하게 퍼뜨려(long-tail 품목 노출을 늘려) 성능을 개선하였다 <sup>2</sup>. 실제로 고르게 분포된 임베딩은 인기도 편향을 완화하고 긴 꼬리 아이템 추천 성능을 높이는 것으로 알려져 있다 <sup>3</sup>. 그러나 지나친 균일성 추구는 비슷한 사용자-아이템 쌍을 정렬하는 능력을 떨어뜨려 성능 저하를 초래할 수 있음도 관찰되었다 <sup>4</sup>.

또한, 사용자 중심 관점에서 추천 다양성과 캘리브레이션의 중요성이 제기되었다. 예를 들어 Kleinberg et al.은 추천 리스트가 사용자의 다양한 관심사를 균형 있게 반영해야 한다고 강조하며 <sup>5</sup>, 추천 아이템 분포와 사용자의 선호 분포 간 불일치 문제를 지적하였다. 정보 이론적 관점에서는, 대조 학습에서 InfoNCE 손실이 KL 기반 상호정보 최대화와 밀접하게 연관됨이 밝혀졌다 <sup>6</sup>. 즉, 임베딩의 균일화는 정보 엔트로피를 최대화하여 표현의 정보량을 보존하는 효과가 있다 <sup>1</sup>. 하지만 기존 방법들은 이러한 정보 이론 척도를 명시적으로 정규화 항목으로 사용하지 않고, 주로 전체 데이터 분포 관점에서만 고려하였다. 따라서, 추천의 다양성과 정확성 간 균형을 위해 **정보 이론적 정규화(엔트로피 및 KL 발산)**를 도입하는 새로운 접근이 필요하다.

## 문제 정의

본 연구에서 정의하는 문제는 대조 학습 기반 추천 시스템에 **정보 이론적 제약**을 통합하는 것이다. 구체적으로, 각 사용자  $u$ 의 과거 상호작용으로 추정된 관심사 분포  $P_u$ 와 모델이 생성하는 추천 항목 분포  $Q_u$ 가 주어질 때, 우리는 대조 학습 손실  $L_{\text{CL}}$ 와 함께 KL 발산  $D_{\text{KL}}(P_u \| Q_u)$ 를 최소화하고 Shannon 엔트로피  $H(Q_u)$ 를 최대화하는 새로운 학습 목표를 설정한다. 즉, 대조 학습을 통해 사용자-아이템 임베딩 간 일치를 극대화하는 동시에,

- **KL 발산 최소화**: 추천 리스트의 분포가 사용자의 선호 분포에 가까워지도록 함.
- **엔트로피 최대화**: 추천 리스트에 다양한 아이템이 포함되도록 함.

이로써 사용자별 맞춤성을 유지하며 추천의 다양성과 신뢰도를 높일 수 있다. 수식으로는 다음과 같은 결합 손실 함수를 고려한다:

$$L_{\text{total}} = L_{\text{CL}} + \alpha \sum_u D_{\text{KL}}(P_u \| Q_u) - \beta \sum_u H(Q_u),$$

여기서  $\alpha, \beta$ 는 균형 하이퍼파라미터이다. 본 연구 문제는 위와 같은 정보 이론적 정규화 항이 포함된 대조 학습 기반 추천 모델의 설계 및 최적화로 정의된다.

## 연구 목표 및 기여

본 연구의 주요 목표와 기대되는 기여는 다음과 같다:

1. **새로운 문제 제시**: 대조 학습 기반 추천에서 KL 발산과 엔트로피 정규화를 포함한 손실 함수를 도입하여, 사용자 선호 분포와 추천 분포를 동시에 최적화하는 새로운 문제를 명확히 정의한다.
2. **방법론 개발**: 대조 학습 손실에 정보 이론적 정규화를 결합한 새로운 모델을 제안한다. 기존의 SimGCL [7] 같은 기법은 가우시안 노이즈를 활용하여 표현의 균일성을 조절하지만, 본 연구에서는 사용자 관심 분포와 추천 분포 간 KL 발산 최소화 및 추천 분포 엔트로피 최대화를 통한 직접적 제어를 제안한다.
3. **이론적 분석**: 제안하는 통합 손실 함수의 학습 특성을 분석한다. 예를 들어, 균일화 정도 조절 및 일반화 성능 간의 상호관계를 정보 병목(Information Bottleneck) 관점에서 고찰하며 [8], KL/엔트로피 항이 모델 최적화에 미치는 영향을 수리적으로 연구할 것이다.
4. **실험 평가**: MovieLens, Amazon, Yelp 등 공개 추천 데이터셋을 이용해 제안 방법을 평가한다. 기존 LightGCN, SGL, SimGCL 등과 비교하여 추천 정확도(Recall, NDCG)와 다양도(Shannon 엔트로피, Gini 지수 등), 캘리브레이션 지표(KL divergence between user profile and recommendation)를 측정한다. 이를 통해 제안법이 실질적으로 사용자 맞춤 분포 반영과 추천 다양성 향상에 기여함을 입증할 계획이다.

이상의 목표를 통해 **개인화 추천의 다양성과 정확성 간 균형**을 위한 새로운 연구 방향을 제시한다.

## 연구 방법론

제안하는 접근법은 대조 학습 기반 임베딩 학습과 정보 이론적 정규화를 결합한다. 우선 사용자는 일반적인 방법(예: 협업 필터링)으로 학습된 임베딩  $\mathbf{z}_u, \mathbf{z}_i$ 를 갖는다. 대조 학습 손실  $L$ 은 사용자  $u$ 와 양성 아이템  $i$ 를 가깝게, 음성 아이템  $j$ 를 멀게 학습시키는 InfoNCE 형태로 구성한다. 여기에 사용자의 관심사 분포  $P_u$ (예: 카테고리별 선호도)와 모델 예측 분포  $Q_u$ (추천 항목들의 분포) 간 KL 발산과  $Q_u$ 의 엔트로피 정규화를 추가한다. 예를 들어,

$$L_{\text{total}} = -\sum_{(u,i^+)} \log \frac{\exp(\mathbf{z}_u^\top \mathbf{z}_{i^+})}{\sum_j \exp(\mathbf{z}_u^\top \mathbf{z}_j)} + \alpha D_{\text{KL}}(P_u \| Q_u) - \beta H(Q_u),$$

와 같이 손실 함수를 설계한다. 여기서 첫 항은 기존 대조 학습, 두 번째 항은 분포 정합(calibration), 세 번째 항은 추천 다양성 확보를 위한 항이다.

이론적으로는 손실 함수의 그래디언트 구조와 일반화 성능 경계를 분석할 계획이다. Uniformity-Alignment 이론 [8]을 차용하여, 엔트로피 정규화 항이 표현 분포에 미치는 영향을 파악한다. 또한 정보 병목 관점에서, KL 제약이 불필요 정보를 억제하여 표현을 압축(compress)함으로써 과적합을 완화할 수 있음을 분석한다.

실험적으로는 LightGCN과 같은 기본 협업 필터링 모델에 제안 손실을 추가하여 학습한다. MovieLens, Yelp, Amazon 등 다양한 규모의 데이터셋으로 실험을 수행하며, 기존 모델 대비 성능을 비교한다. 특히 추천 목록의 카테고리 분포와 사용자 프로필 분포 간 KL divergence를 측정하여 캘리브레이션 향상 여부를 평가한다. 또한 Shannon 엔트로피 등으로 추천 다양도를 정량화하고, 정확도 지표의 변화를 통해 균형 효과를 분석한다.

## 정보 이론적 관련성

본 연구에서 Shannon 엔트로피와 Kullback-Leibler(KL) 발산은 핵심 역할을 한다. **KL 발산**  $D_{\text{KL}}(P_u \| Q_u)$ 는 두 확률 분포 간의 차이를 측정하는 상대 엔트로피이다. 본 모델에서는 사용자의 과거 선호 분포  $P_u$ 와 모델이 예측한 추천 분포  $Q_u$  사이의 KL 발산을 최소화함으로써 추천 결과를 사용자 특성에 맞게 정렬(calibration)한다. 예를 들어, ML-100K 영화 추천에서 사용자가 좋아하는 장르 분포와 추천 리스트 장르 분포 간 KL 값이 작을수록 캘리브레이션

선이 잘 되었다고 볼 수 있다. 이처럼 KL 발산을 손실 함수에 포함하면 통계적 유사성을 높여 정량적 조절이 가능하다. 실제로 BLIN 모델에서도 대조 학습에서 파생된 분포들 간 정합을 위해 이중 방향 KL 손실을 도입한 바 있다 <sup>9</sup>.

반면, 엔트로피  $H(Q_u) = -\sum_i Q_u(i) \log Q_u(i)$ 는 분포의 불확실성(다양성)을 나타내는 척도다. 추천 결과의 엔트로피를 최대화하면, 특정 아이템에 치우치지 않고 다양한 아이템을 추천하도록 유도한다. 대조 학습 관점에서 보면, 표현의 균일화를 통해 임베딩 공간 엔트로피를 증가시키는 것이 일반적 전략이다 <sup>1</sup>. 이 연구에서도 각 사용자별로 추천 분포의 엔트로피를 높여 균일성을 확보한다. 단, 선행 연구가 임베딩 수준의 균일화를 주로 다룬 것과 달리, 우리는 직접 추천 목록 분포의 엔트로피를 조절한다. 이는 추천 결과의 다양성과 사용자 만족도를 높이는 데 기여한다. 한편, 지나친 엔트로피 증가는 정확도 손실을 초래할 수 있으므로 <sup>4</sup>,  $\beta$  값을 조절하여 트레이드오프를 설정할 예정이다.

결과적으로 KL 발산과 엔트로피 항은 각각 **정확성과 다양성** 사이의 균형을 조율하는 정보 이론적 정규화로 작용한다. 이 두 척도는 서로 밀접하게 연관되어 있으며, 대조 학습의 InfoMax 원리 <sup>6</sup> 와 조화를 이루어 사용자 맞춤형 다양성을 지원한다.

## 관련 연구

대조 학습 기반 추천과 정보 이론적 접근에 관한 기존 연구들과 본 제안의 차별점을 비교한다. 대조 학습 추천 분야에서는 SGL, SimGCL 등 그래프 증강을 활용한 기법들이 있다. 예컨대, Yu 등은 가우시안 노이즈를 통해 표현 균일화를 조절하는 SimGCL(XSimGCL) 방법을 제안했다 <sup>7</sup>. 하지만 이들은 전체 노드 임베딩의 분포에만 중점을 두고, 사용자 수준의 분포 일치나 엔트로피 정규화는 고려하지 않았다. 정보 이론 측면에서는 다양한 연구가 존재한다. Wei 등은 그래프 대조 학습에 정보 병목 원리(Information Bottleneck)를 도입하여 무관 정보 제거와 표현 풍부화에 성공하였다 <sup>10</sup>. Yang 등은 멀티미디어 추천에서 IB를 통해 관련 없는 특징을 필터링했다. 그러나 이들 연구는 주로 그래프 구조 최적화나 특징 압축에 초점을 맞췄으며, 추천 목록의 분포 조절에는 직접 연결되지 않는다. 또, 순차 추천 BLIN 모델은 서로 다른 시퀀스 표현 간 분포 정렬을 위해 양방향 KL 발산 손실을 도입한 바 있다 <sup>9</sup>. 캘리브레이션 관련 연구에서는 Steck 등(2018)이 사용자의 선호 분포를 반영하는 추천의 필요성을 제안했지만, 본 연구처럼 학습 손실에 직접 KL 항을 포함한 방법은 거의 없다.

요약하면, 기존 대조 학습 추천 연구들은 임베딩 균일화에 주력했고, 정보 이론적 추천 연구들은 주로 특징 선택이나 공정성에 초점을 맞추었다. 본 연구는 이들 간의 차이를 **대조 학습+정보 이론** 통합 관점에서 연결하며, 사용자별 분포 캘리브레이션과 다양성 증대를 위한 새로운 정규화 기법을 제시한다. 특히 **KL 발산 및 엔트로피를 손실 함수에 명시적으로 도입함**으로써 기존 접근과 차별화된 문제 설정을 제공한다.

## 결론

본 제안에서는 추천 시스템에 정보 이론적 정규화를 결합한 대조 학습 기법을 개발하는 것을 목표로 한다. 사용자 선호 분포에 기반한 KL 발산 최소화와 추천 분포 엔트로피 최대화를 대조 학습 손실에 도입함으로써, 추천 결과의 정확도와 다양성을 동시에 높이려 한다. 이론적 분석과 실험을 통해 제안 방법의 유효성을 검증하고, 추천 품질 개선을 기대한다. 궁극적으로, 본 연구는 기존 추천 방법들이 다루지 못했던 **사용자 분포 캘리브레이션**과 **정보 이론적 관점의 정규화**를 접목하여, 맞춤형 추천의 새 지평을 열 것으로 기대한다.

## 참고 문헌

- Kleinberg, J., Ryu, E., & Tardos, É. (2023). Calibrated Recommendations for Users with Decaying Attention. arXiv:2302.03239. <sup>5</sup>
- Wei, C., Liang, J., Liu, D., & Wang, F. (2022). Contrastive Graph Structure Learning via Information Bottleneck for Recommendation. NeurIPS 2022. <sup>10</sup>
- Yu, J., Xia, X., Chen, T., Cui, L., Hung, N. Q. V., & Yin, H. (2023). XSimGCL: Towards Extremely Simple Graph Contrastive Learning for Recommendation. IEEE TKDE, 35(10). <sup>11</sup>

- Bai, Y., Wang, H., & He, J. (2024). Blin: A Multi-Task Sequence Recommendation Based on Bidirectional KL-Divergence and Linear Attention. *Mathematics*, 12(15), 2391. <sup>12</sup>
  - Chen, T., He, K., & Zhang, Y. (2024). Understanding and Generalizing InfoNCE-based Contrastive Learning. *arXiv:2402.10150*. <sup>6</sup>
- 

<sup>1</sup> <sup>2</sup> <sup>7</sup> Intent-Guided Heterogeneous Graph Contrastive Learning for Recommendation

<https://arxiv.org/html/2407.17234v1>

<sup>3</sup> <sup>4</sup> <sup>8</sup> <sup>11</sup> [arxiv.org](https://arxiv.org)

<https://arxiv.org/pdf/2209.02544>

<sup>5</sup> Calibrated Recommendations for Users with Decaying Attention

<https://arxiv.org/html/2302.03239v2>

<sup>6</sup> -MICL: Understanding and Generalizing InfoNCE-based Contrastive Learning

<https://arxiv.org/html/2402.10150v1>

<sup>9</sup> <sup>12</sup> Blin: A Multi-Task Sequence Recommendation Based on Bidirectional KL-Divergence and Linear Attention

<https://www.mdpi.com/2227-7390/12/15/2391>

<sup>10</sup> Contrastive Graph Structure Learning via Information Bottleneck for Recommendation

[https://proceedings.neurips.cc/paper\\_files/paper/2022/hash/803b9c4a8e4784072fdd791c54d614e2-Abstract-Conference.html](https://proceedings.neurips.cc/paper_files/paper/2022/hash/803b9c4a8e4784072fdd791c54d614e2-Abstract-Conference.html)